



CS 2568/45

เค้าโครงโครงงานโครงงานทางวิทยาการคอมพิวเตอร์ 1

ระบบวิเคราะห์ภาพเอกซเรย์ทรวงอกออนไลน์ด้วยการเรียนรู้เชิงลึกและ
ปัญญาประดิษฐ์แบบอธิบายได้

Online X-ray Analysis with Deep Learning and Explainable ai
โดย

653380192-7 นายเจษฎากร ดุจพ่ายัพ

653380194-3 นายฐาปกรณ์ เมืองจันทร์

อาจารย์ที่ปรึกษาโครงงาน : ดร. พบพร ด่านวิรุทัย

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354771 โครงงานทางวิทยาการคอมพิวเตอร์ 1

ภาคเรียน 1 ปีการศึกษา 2568

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

เดือน กรกฎาคม พ.ศ. 2568

รายละเอียดการเขียนเค้าโครงโครงการงานทางวิทยาการคอมพิวเตอร์ 1

การเสนอเค้าโครงโครงการงานคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ นาย / นางสาว เจษฎากร ดุจฉาย

รหัสประจำตัว 653380192-7

Mr. / Miss Jetsadakorn Dutphayap

นาย / นางสาว ธาปกรณ์ เมืองจันทร์

รหัสประจำตัว 653380194-3

Mr. / Miss Thapakorn Muangchan

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงการ ดร. พบพร ด่านวิรุทัย

Project Advisor Dr. Pobporn Danvirutai

1. ชื่อหัวข้อโครงการ

ภาษาไทย ระบบวิเคราะห์ภาพเอกซเรย์ทรวงอกออนไลน์ด้วยการเรียนรู้เชิงลึกและปัญญาประดิษฐ์แบบอธิบายได้

ภาษาอังกฤษ Online X-ray Analysis with Deep Learning and Explainable ai

2. หลักการและเหตุผล

วัณโรคเป็นโรคติดต่อที่ร้ายแรง และยังคงเป็นปัญหาทางสาธารณสุขที่สำคัญในหลายประเทศ โดยเฉพาะในประเทศกำลังพัฒนา การวินิจฉัยเบื้องต้นมักอาศัยการถ่ายภาพเอกซเรย์ทรวงอก (Chest X-ray) เพื่อดูความผิดปกติของปอด อย่างไรก็ตาม การอ่านผลภาพเอกซเรย์นั้นจำเป็นต้องอาศัยความเชี่ยวชาญของรังสีแพทย์ ซึ่งอาจขาดแคลนในบางพื้นที่หรือสถานการณ์ฉุกเฉิน

การประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) โดยเฉพาะการเรียนรู้เชิงลึก (Deep Learning) สามารถช่วยในการวิเคราะห์ภาพเอกซเรย์ได้อย่างรวดเร็วและแม่นยำ ลดภาระงานของบุคลากรทางการแพทย์ และช่วยคัดกรองผู้ป่วยเบื้องต้นได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม โมเดล Deep Learning ส่วนใหญ่มักมีลักษณะเป็น “กล่องดำ” (Black Box) ซึ่งหมายความว่า แม้จะให้ผลลัพธ์ที่แม่นยำ แต่ไม่สามารถอธิบายเหตุผลของการตัดสินใจได้อย่างชัดเจน

เพื่อเพิ่มความโปร่งใสและความน่าเชื่อถือของระบบ AI จึงมีการนำแนวคิด “ปัญญาประดิษฐ์แบบอธิบายได้” (Explainable AI: XAI) เข้ามาช่วย โดยสามารถแสดงให้เห็นว่าโมเดลให้ความสำคัญกับจุดใดในภาพ เช่น บริเวณใดของปอดที่อาจบ่งชี้ถึงอาการของวัณโรค ซึ่งช่วยให้บุคลากรทางการแพทย์สามารถเข้าใจและยอมรับผลลัพธ์จากโมเดลได้มากยิ่งขึ้น

3. วัตถุประสงค์ของโครงการ

3.1 เพื่อพัฒนาโมเดล Deep Learning สำหรับจำแนกภาพเอกซเรย์ทรวงอกออกเป็น 2 กลุ่ม ได้แก่ ภาพปกติ และภาพที่แสดงอาการของวัณโรค ด้วยความแม่นยำสูง

3.2 เพื่อนำเทคนิคปัญญาประดิษฐ์แบบอธิบายได้ (Explainable AI: XAI) เช่น Grad-CAM, LIME หรือ SHAP มาใช้เพื่อแสดงเหตุผลประกอบการตัดสินใจของโมเดล

3.3 เพื่อสร้างเว็บแอปพลิเคชันที่ใช้งานง่ายสำหรับแพทย์หรือบุคลากรทางการแพทย์ในการอัปโหลดภาพเอกซเรย์ และรับผลการวิเคราะห์พร้อมคำอธิบายที่เข้าใจได้

3.4 เพื่อประเมินและตั้งเป้าหมายให้ระบบสามารถจำแนกภาพได้ด้วยความแม่นยำ (Accuracy) **ไม่ต่ำกว่า 85%** และค่า AUC อย่างน้อย **0.90** บนชุดข้อมูลทดสอบ

4. ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 โครงข่ายประสาทเทียม (Artificial Neural Networks - ANNs)

โครงข่ายประสาทเทียมเป็นระบบที่ได้รับแรงบันดาลใจจากสมองมนุษย์และถูกนำมาใช้ในการเรียนรู้ของเครื่องเพื่อเลียนแบบการเรียนรู้ของมนุษย์ โครงสร้างของ ANN ประกอบด้วย ชั้นข้อมูลนำเข้า ชั้นข้อมูลส่งออก และชั้นซ่อนซึ่งอาจมีหรือไม่มีทำหน้าที่แปลงข้อมูลให้เป็นรูปแบบที่มีความหมายโครงข่ายประสาทเทียมมีความสามารถโดดเด่นในการค้นหารูปแบบที่ซับซ้อนในข้อมูล ความก้าวหน้าของ ปัญญาประดิษฐ์ ที่ใช้โครงข่ายประสาทเทียม มาจาก อัลกอริธึมย้อนกลับ (Backpropagation) ซึ่งช่วยให้เครือข่ายปรับค่าของชั้นซ่อนเมื่อผลลัพธ์ที่ได้ไม่ถูกต้อง โครงข่ายประสาทเชิงลึก (Deep Learning Neural Networks) ใช้หลายชั้นเพื่อดึงคุณลักษณะต่าง ๆ ออกมา ประเภทหลักของโครงข่ายประสาทเทียมได้แก่

- 1) โครงข่ายแบบฟีดฟอร์เวิร์ด (Feedforward Networks): ข้อมูลไหลไปในทิศทางเดียว
- 2) โครงข่ายแบบวนซ้ำ (Recurrent Networks): ข้อมูลสามารถไหลได้หลายทิศทาง เหมาะกับงานที่ซับซ้อน เช่น การรู้จำภาษา
- 3) นอกจากนี้ยังมีโครงข่ายประเภทอื่น เช่น โครงข่ายคอนโวลูชัน (Convolutional Networks) และ โครงข่ายโบลต์ซมันน์ (Boltzmann Networks) (Nwadiugwu, 2020)

4.2 การเรียนรู้เชิงลึก (Deep Learning)

การเรียนรู้เชิงลึกเป็นส่วนหนึ่งของการเรียนรู้ของเครื่องที่ใช้โครงข่ายประสาทเทียมหลายชั้น (Artificial Neural Networks) ซึ่งทำให้ระบบสามารถเรียนรู้คุณลักษณะที่ซับซ้อนจากข้อมูลที่มีโครงสร้างหลายมิติได้ โครงข่ายประสาทเทียมสามารถจำแนกคุณสมบัติที่ซับซ้อนของภาพ เอกซเรย์ ได้ เช่น ความหนาของเนื้อเยื่อ การเปลี่ยนแปลงของลักษณะทางกายภาพ และความแตกต่างของโครงสร้างต่าง ๆ ในร่างกายการเรียนรู้ของเครื่อง คือส่วนย่อยของปัญญาประดิษฐ์ที่พัฒนาขึ้นจากแนวคิดที่ว่าระบบจะฉลาดขึ้นได้หากมีข้อมูลให้เรียนรู้ โดยอาศัยข้อมูลขนาดใหญ่, การจำแนกรูปแบบ, และหลักตรรกศาสตร์ เพื่อให้เครื่องจักรสามารถตัดสินใจได้ด้วยตนเองโดยไม่ต้องพึ่งพามนุษย์ หลังจากเรียนรู้แล้ว ML จะสามารถเลือกและตัดสินใจตอบสนองต่อคำสั่งที่มนุษย์ป้อนเข้าไปได้อย่างชาญฉลาด โมเดลของ ML สามารถปรับแต่งให้เรียนรู้ในหัวข้อเฉพาะด้านได้ ทำให้มีความแม่นยำและมีประสิทธิภาพสูงการทำงานของ การเรียนรู้ของเครื่อง อาศัยอัลกอริทึมฝึกฝน (Training Algorithm) กับชุดข้อมูลเพื่อให้ได้ผลลัพธ์ตามที่ต้องการ เช่น การระบุรูปแบบหรือจดจำวัตถุ กระบวนการนี้คือการปรับแต่งโมเดลเพื่อให้ ปัญญาประดิษฐ์ คาดการณ์คำตอบที่ถูกต้องโดยอ้างอิงจากข้อมูลที่เคยเรียนรู้ ความแม่นยำขึ้นอยู่กับขนาดและคุณภาพของข้อมูลที่ใช้ฝึกฝน กระบวนการฝึกฝนจะวนซ้ำจนกว่าจะได้ผลลัพธ์ที่แม่นยำตามที่คาดหวัง มหาวิทยาลัยแคลิฟอร์เนีย เบิร์กลีย์ แบ่งการทำงานของอัลกอริทึมการเรียนรู้เชิงลึก

ออกเป็น 3 ส่วนคือ กระบวนการตัดสินใจ (Decision Process), คุณสมบัติข้อผิดพลาด (Error Function), และ กระบวนการปรับแต่งโมเดล (Model Optimization Process) ประเภทของ การเรียนรู้ของเครื่อง แบ่งออกเป็น 3 ประเภทหลัก

- 1) Supervised Learning (การเรียนรู้แบบมีผู้สอน): ใช้การติดป้ายกำกับ (Label) ในการจำแนกข้อมูลการเรียนรู้ ตัวอย่างอัลกอริทึมเช่น Linear Regression, Decision Trees.
- 2) Unsupervised Learning (การเรียนรู้แบบไม่มีผู้สอน): ใช้ข้อมูลที่ไม่มีป้ายกำกับหรือไม่มีโครงสร้าง เพื่อให้โมเดลเรียนรู้และจัดกลุ่มข้อมูลด้วยตนเอง ตัวอย่างอัลกอริทึมเช่น K-Means Clustering.
- 3) Reinforcement Learning (การเรียนรู้จากการเสริมแรง): ฝึกฝนโดยการ "เรียนรู้ด้วยการลงมือทำ" ผ่านการทดสอบและประสบการณ์ที่ผิดพลาด โดยมี "ตัวแทน" (Agent) ทำการทดสอบซ้ำๆ จนได้ผลลัพธ์ที่น่าพอใจนอกจากนี้ยังมี Semi-Supervised Learning ที่ใช้ข้อมูลที่มีป้ายกำกับเพียงบางส่วน (Tangerine., What is Deep Learning?, n.d.)

4.3 โครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Network: CNN)

โครงข่ายประสาทเทียมชนิดหนึ่งที่มีความนิยมอย่างมากในงานด้านการประมวลผลภาพและสัญญาณรูปแบบต่าง ๆ โดยมีการพัฒนาขึ้นครั้งแรกในปี 1980s โดย Yann LeCun ในรูปแบบของ LeNet ซึ่งเป็นการประยุกต์ใช้ในการจดจำตัวเลขจากภาพขนาดเล็ก อย่างไรก็ตาม โครงข่ายประสาทเทียมแบบคอนโวลูชัน เริ่มมีบทบาทมากขึ้นในช่วงหลังจากปี 2012 ที่ AlexNet ซึ่งเป็นโมเดล โครงข่ายประสาทเทียมแบบคอนโวลูชัน ที่มีชั้นหลายชั้น (deep network) ประสบความสำเร็จในการแข่งขัน ImageNet และเป็นจุดเริ่มต้นที่สำคัญสำหรับ การเรียนรู้เชิงลึก ในงานด้านการรู้จำภาพ

โครงข่ายประสาทเทียมแบบคอนโวลูชัน ประกอบด้วยชั้นหลัก ๆ ดังนี้

1. เลเยอร์การคอนโวลูชัน (Convolutional Layer)

เป็นเลเยอร์สำคัญที่ใช้ในการดึงฟีเจอร์จากข้อมูลภาพ โดยทำการคำนวณผ่านฟิลเตอร์หรือคอนโวลูชันเคอร์เนล ซึ่งเป็นเมทริกซ์ขนาดเล็กที่สไลด์ผ่านภาพเพื่อดึงลักษณะเฉพาะ เช่น เส้นขอบ, รูปร่าง, หรือพื้นผิวในภาพ

2. เลเยอร์การลดขนาด (Pooling Layer)

มีหน้าที่ลดขนาดของข้อมูลหรือคุณลักษณะ เพื่อให้โมเดลมีความทนทานต่อการเปลี่ยนแปลงเล็กน้อย ในตำแหน่งของวัตถุในภาพ ลดจำนวนพารามิเตอร์ และลดการใช้ทรัพยากรคอมพิวเตอร์

3. เลเยอร์เชื่อมต่อเต็ม (Fully Connected Layer)

รวมข้อมูลจากเลเยอร์สุดท้ายของการคอนโวลูชันและการ pooling จะถูกส่งไปยังเลเยอร์ fully connected ซึ่งมีหน้าที่ในการตัดสินใจสุดท้ายเกี่ยวกับการจำแนกประเภทข้อมูล โดยในเลเยอร์นี้จะมีนิวรอนทั้งหมดเชื่อมต่อกับนิวรอนในเลเยอร์ก่อนหน้าอย่างสมบูรณ์ ทำให้สามารถรวมข้อมูลจากฟีเจอร์ที่เรียนรู้ได้ทั้งหมดเพื่อสร้างการทำนาย (Mindphp, 2023)

4.4 ประสาทเทียมเชิงลึกแบบเรซิดิวอัล 50 ชั้น (ResNet-50)

โครงข่ายประสาทเทียมเชิงลึกแบบเรซิดิวอัล 50 ชั้นเป็นโครงข่ายประสาทเทียมแบบคอนโวลูชัน ที่ได้รับการพัฒนาโดย (He et al., 2016) ภายใต้แนวคิดเรเดียลเลนนิง เพื่อลดปัญหาการฝึกโมเดลเชิงลึก โดยเฉพาะปัญหา Vanishing Gradient ซึ่งเป็นอุปสรรคสำคัญของการเรียนรู้เชิงลึก โครงข่ายประสาทเทียมเชิงลึกแบบเรซิดิวอัล 50 ชั้น เป็นหนึ่งในสถาปัตยกรรมของตระกูลเรสเนต(ResNet :Residual Networks) ซึ่งมีหลายเวอร์ชัน โดยตัวเลขที่ต่อท้ายหมายถึงจำนวนชั้น (layers) ในโครงข่าย

ซึ่งในกรณีของ โครงข่ายประสาทเทียมเชิงลึกแบบเรซิวิวอัล 50 ชั้น นั้นมีทั้งหมด 50 ชั้น จุดเด่นของ โครงข่ายประสาทเทียมเชิงลึกแบบเรซิวิวอัล 50 ชั้น คือการการเชื่อมต่อข้าม หรือ การเชื่อมต่อทางลัดที่ช่วยให้สัญญาณสามารถไหลผ่านโครงข่ายได้โดยไม่สูญเสียข้อมูลมากเกินไป ทำให้สามารถฝึกโมเดลที่ลึกขึ้นได้อย่างมีประสิทธิภาพโดยไม่เกิดปัญหา การหายไปของเกรเดียนต์ (Vanishing Gradient) ซึ่งมักเกิดขึ้นในโมเดลแบบเดิมที่มีชั้นจำนวนมาก ด้วยโครงสร้างที่ลึกและเทคนิคการเรียนรู้แบบสภาพตกค้าง (Residual Learning) โครงข่ายประสาทเทียมเชิงลึกแบบเรซิวิวอัล 50 ชั้น จึงสามารถเรียนรู้คุณลักษณะที่ซับซ้อนของข้อมูลได้ดี และมักถูกนำมาใช้ในงานด้าน การจำแนกภาพ, การตรวจจบบั๊ก และ การวิเคราะห์ทางการแพทย์ (He, 2016)

2.1.5. ซัพพอร์ตเวกเตอร์แมชชีน

ซัพพอร์ตเวกเตอร์แมชชีน เป็นหนึ่งในอัลกอริทึมที่ได้รับความนิยมในด้านการเรียนรู้ของเครื่องโดยเฉพาะในงานที่เกี่ยวข้องกับการจำแนกประเภท (Classification) และการถดถอย (Regression) ซัพพอร์ตเวกเตอร์แมชชีน ทำงานโดยการค้นหาเส้นแบ่งเขต (Cortes C. &, 1995)

4.5. เอ็กซ์จีบูสต์ (XGBoost)

เอ็กซ์จีบูสต์ โลบารีการเรียนรู้ของเครื่องแบบโอเพนซอร์สที่ทำงานแบบกระจาย ซึ่งใช้อัลกอริทึม Gradient Boosted Decision Trees ซึ่งเป็นอัลกอริทึมการเรียนรู้แบบมีผู้สอนที่ใช้การสืบ descent แบบ gradient เอ็กซ์จีบูสต์ เป็นที่รู้จักในด้านความเร็ว, ประสิทธิภาพ, และความสามารถในการปรับขนาด ได้ดีกับชุดข้อมูลขนาดใหญ่ พัฒนาโดย Tianqi Chen จาก University of Washington โดยเป็น การใช้งานขั้นสูงของ เกรเดียนต์บูสต์ดั้งเดิม ต้นไม้ผู้เรียนอ่อนหลายต้น เข้าด้วยกันเพื่อสร้าง ผู้เรียนที่แข็งแกร่ง โดยการบวกค่าคงเหลือ Gradient Boosted Decision Trees เป็นประเภทหนึ่งของอัลกอริทึม Boosting ที่ใช้ gradient descent เช่นเดียวกับวิธี Boosting อื่นๆ เกรเดียนต์บูสต์ดั้งเดิมเริ่มต้นด้วย ผู้เรียนอ่อน เพื่อทำการทำนาย ต้นไม้ตัดสินใจแรกใน เกรเดียนต์บูสต์ดั้งเดิมเรียกว่า base learner จากนั้นจะมีการสร้างต้นไม้ใหม่ๆ เพิ่มเติมโดยอิงจากข้อผิดพลาดของผู้เรียนพื้นฐาน อัลกอริทึมจะคำนวณ ค่าคงเหลือของการทำนายของแต่ละต้นไม้เพื่อพิจารณาว่าการทำนายของโมเดลนั้นแตกต่างจากความเป็นจริงมากน้อยเพียงใด จากนั้นค่าคงเหลือจะถูกรวมเข้าด้วยกันเพื่อประเมินโมเดลด้วย ฟังก์ชันการสูญเสีย (loss function) Gradient descent ใช้เพื่อลดการสูญเสียและปรับปรุงประสิทธิภาพของโมเดลเมื่อเราฝึกโมเดลใหม่ คุณสมบัติเด่นของ เอ็กซ์จีบูสต์ ได้แก่

- 1) การประมวลผลแบบขนานและแบบกระจาย
- 2) อัลกอริทึม prefetching ที่ตระหนักถึงแคช ซึ่งช่วยลดเวลาการทำงานสำหรับชุดข้อมูลขนาดใหญ่
- 3) การทำ Regularization ในตัว ซึ่งช่วยให้ได้ผลลัพธ์ที่ดีกว่า เกรเดียนต์บูสต์ดั้งเดิมทั่วไปใน scikit-learn
- 4) การจัดการค่าที่หายไป (missing values) โดยใช้อัลกอริทึมที่ตระหนักถึงความกระจุกกระจายของข้อมูล

ในการใช้งาน เอ็กซ์จีบูสต์ โดยทั่วไป จะเริ่มต้นด้วยการแบ่งข้อมูลเป็นชุดฝึกและชุดทดสอบ จากนั้น แปลงข้อมูลเป็นรูปแบบ DMatrix ที่ เอ็กซ์จีบูสต์ คาดหวัง จากนั้นจึงสร้างอินสแตนซ์ของโมเดล เอ็กซ์จีบูสต์ และเลือก ฟังก์ชันวัตถุประสงค์ (objective function) ที่เหมาะสมกับงาน หลังจากฝึกโมเดลแล้ว จะมีการประเมินประสิทธิภาพโดยเปรียบเทียบค่าที่ทำนายได้กับค่าจริงในชุดทดสอบการปรับแต่งพารามิเตอร์ของโมเดลเป็นขั้นตอนสำคัญในการปรับปรุงประสิทธิภาพของโมเดล โดย เอ็กซ์จีบูสต์ มีไฮเปอร์พารามิเตอร์ที่สำคัญหลายตัว เช่น learning rate (eta) ซึ่งควบคุมอัตราการเรียนรู้ ซึ่งระบุจำนวนต้นไม้ที่จะสร้างซึ่งควบคุมการลดการสูญเสียต่ำสุดที่จำเป็นสำหรับการแยกโหนด และ max_depth ซึ่งกำหนดความลึกสูงสุดของแต่ละต้นไม้เอ็กซ์จีบูสต์ ถูกนำไปเปรียบเทียบกับอัลกอริทึมบูสต์อื่น ๆ เช่น เอดีเอช และ แคมพูส มีการใช้งานหลากหลาย เช่น การเรียนรู้เพื่อจัดอันดับ, การทำนายอัตราการคลิกโฆษณา, การทำนายยอดขาย, การจำแนกมลภาวะ, และยังเป็นอัลกอริทึมที่ได้รับความนิยมในการแข่งขันแคคเกิล (Chen, 2016)

4.6 การเพิ่มข้อมูล (Data Augmentation)

เทคนิคที่ใช้ในการขยายขนาดชุดข้อมูลภาพโดยการประยุกต์ใช้การแปลงต่าง ๆ กับภาพที่มีอยู่เดิม ซึ่งเป็นประโยชน์อย่างมากเมื่อทำงานกับโมเดลการเรียนรู้เชิงลึกอย่างโครงข่ายประสาทเทียมแบบคอนโวลูชัน ที่มักต้องการชุดข้อมูลขนาดใหญ่เพื่อการเรียนรู้ที่มีประสิทธิภาพ การเพิ่มข้อมูลช่วยปรับปรุงความสามารถในการปรับตัวทั่วไปของโมเดล (generalization) โดยการเพิ่มความหลากหลายและทำให้โมเดลมีความทนทานต่อการเปลี่ยนแปลงของข้อมูลเข้า (Shorten, A survey on Image Data Augmentation for Deep Learning, 2019)

4.7 ปัญญาประดิษฐ์ที่สามารถอธิบายได้ (Explainable AI: XAI)

เป็นแนวทางที่ช่วยให้การตัดสินใจของโมเดลปัญญาประดิษฐ์สามารถถูกอธิบายและเข้าใจได้โดยมนุษย์ โดยเฉพาะในสาขาที่มีความสำคัญสูง เช่น การแพทย์ การที่บุคลากรทางการแพทย์สามารถเข้าใจเหตุผลเบื้องหลังคำวินิจฉัยจาก AI ได้ ถือเป็นสิ่งจำเป็น เพื่อสร้างความเชื่อมั่นและความโปร่งใสในการใช้งานระบบเหล่านี้ ปัญหาสำคัญของ AI ทางด้านการแพทย์ในปัจจุบันคือ แม้ระบบจะให้ผลลัพธ์ที่แม่นยำ แต่กลับไม่สามารถระบุได้ว่าทำไมถึงได้ผลลัพธ์นั้น ทำให้ขาดความน่าเชื่อถือในทางคลินิก XAI จึงเข้ามามีบทบาทสำคัญในการแสดงให้เห็นว่า โมเดลให้ความสำคัญกับส่วนใดของภาพ เช่น บริเวณที่มีความผิดปกติในภาพ X-ray เพื่อช่วยให้แพทย์สามารถตรวจสอบและยืนยันเหตุผลของ AI ได้อย่างมั่นใจ (Wang, 2024) มีหลายเทคนิคที่นิยมใช้ใน XAI สำหรับโมเดลที่วิเคราะห์ภาพ

4.7.1 Grad-CAM (Gradient-weighted Class Activation Mapping)

เป็นเทคนิคที่แสดง "heatmap" ทับลงบนภาพ X-ray เพื่อชี้ให้เห็นว่าบริเวณใดมีผลต่อการตัดสินใจของโมเดลมากที่สุด

4.7.2 LIME (Local Interpretable Model-Agnostic Explanations)

เป็นวิธีที่ไม่ขึ้นกับโมเดล (model-agnostic) โดยจะทดลองเปลี่ยนบางส่วนของภาพ แล้วสร้างโมเดลย่อยเพื่อดูว่าแต่ละส่วนของภาพส่งผลอย่างไรต่อคำวินิจฉัย

4.7.3 SHAP (SHapley Additive exPlanations)

ใช้หลักการจากทฤษฎีเกม (Shapley value) เพื่อคำนวณว่าแต่ละ pixel หรือ feature ในภาพมี "ค่าน้ำหนัก" ต่อผลลัพธ์มากแค่ไหน

5. วิธีดำเนินการวิจัย

5.1 การรวบรวมและเตรียมข้อมูล

5.1.1 ใช้ชุดข้อมูลภาพเอกซเรย์ทรวงอกแบบเปิด (Public Chest X-ray Datasets) เช่น

1. Kaggle

5.1.2 ดำเนินการปรับปรุงและทำความสะอาดข้อมูลเบื้องต้น

5.1.3 แบ่งชุดข้อมูลออกเป็น 3 ส่วน ได้แก่

1. สำหรับฝึกโมเดล

2. สำหรับปรับค่าพารามิเตอร์

3. สำหรับประเมินประสิทธิภาพของระบบ

5.2 การพัฒนาโมเดล Deep Learning

5.2.1 ออกแบบสถาปัตยกรรมของโมเดลโดยพิจารณาใช้โครงข่ายประสาทเทียม เช่น

1. Convolutional Neural Networks (CNN): เช่น ResNet, DenseNet
2. Vision Transformer (ViT): สำหรับการจำแนกภาพแบบใช้ Attention-based model

5.2.2 ใช้เทคนิคต่าง ๆ เพื่อเพิ่มประสิทธิภาพของโมเดล เช่น

1. Data Augmentation: เพื่อเพิ่มความหลากหลายของข้อมูล
2. Transfer Learning: เพื่อประยุกต์ใช้โมเดลที่ผ่านการฝึกมาแล้ว

5.3 การประยุกต์ใช้เทคนิค XAI (Explainable AI)

5.3.1 ใช้เทคนิคเพื่ออธิบายเหตุผลในการจำแนกภาพของโมเดล ได้แก่

1. Grad-CAM (Gradient-weighted Class Activation Mapping): แสดงบริเวณในภาพที่โมเดลให้

ความสำคัญในการตัดสินใจ

2. LIME (Local Interpretable Model-Agnostic Explanations) และ SHAP (SHapley Additive

exPlanations): อธิบายความสำคัญของแต่ละพิกเซลหรือคุณลักษณะในภาพ

5.4 การพัฒนาเว็บแอปพลิเคชัน

5.4.1 พัฒนาแอปพลิเคชันแบบเว็บเพื่อให้ผู้ใช้งานสามารถเข้าถึงระบบได้ง่าย โดยแบ่งออกเป็น

1. พัฒนาอินเทอร์เฟซผู้ใช้งานด้วย HTML, CSS, และ JavaScript โดยอาจใช้เฟรมเวิร์กอย่าง React.js หรือ

Vue.js

2. พัฒนาเซิร์ฟเวอร์ด้วย Python โดยใช้ Flask หรือ Django ในการเชื่อมต่อกับโมเดล AI และจัดการคำร้อง

ขอจากผู้ใช้

5.4.2 ฟีเจอร์หลักของเว็บแอปพลิเคชัน

1. การอัปโหลดภาพเอกซเรย์ทรวงอก
2. การแสดงผลการจำแนกเป็น “ปกติ” หรือ “วัณโรค”
3. การแสดง Heatmap จาก Grad-CAM หรือผลลัพธ์จาก XAI อื่น
4. การแสดง **ค่าความมั่นใจ (Confidence Score)** เพื่อช่วยให้ผู้ใช้งานเข้าใจความแน่นอนของการจำแนก

6. ขอบเขตและข้อจำกัดของการวิจัย

6.1 ขอบเขตของโครงการ

6.1.1 โครงการนี้มุ่งเน้นการจำแนกภาพถ่ายรังสีทรวงอก (Chest X-ray) ของมนุษย์ให้เป็น 2 ประเภท

1. ปอดปกติ (Normal)
2. ปอดที่มีอาการวัณโรค (Tuberculosis)

6.1.2 ชุดข้อมูลที่เข้ามาจากแหล่งข้อมูลแบบเปิด (Open Dataset) บนเว็บไซต์ **Kaggle** ซึ่งรวมภาพเอกซเรย์ทรวงอกที่มีการระบุประเภทอย่างชัดเจน จำนวนภาพรวมทั้งหมดประมาณ 9,794 ภาพ แบ่งข้อมูลออกเป็น 3 ชุดตามสัดส่วน

1. ข้อมูลสำหรับฝึกโมเดลจำนวน 6,858 ภาพ

2. ข้อมูลสำหรับปรับค่าพารามิเตอร์จำนวน 1,464 ภาพ
3. ข้อมูลสำหรับประเมินประสิทธิภาพของระบบจำนวน 1,464 ภาพ

6.1.3 โครงการจะใช้โมเดล Deep Learning ได้แก่ Convolutional Neural Networks และอาจทดลอง Vision Transformer (ViT) ในการพัฒนาโมเดล

6.1.4 ใช้เทคนิค Explainable AI (XAI) ได้แก่ Grad-CAM, LIME และ SHAP เพื่ออธิบายผลลัพธ์ของโมเดล โดยเน้นให้เห็นว่าบริเวณใดในภาพที่โมเดลใช้ในการตัดสินใจ

6.1.5 มีการพัฒนา **เว็บแอปพลิเคชันต้นแบบ** สำหรับอัปโหลดภาพ X-ray และแสดงผลการจำแนก พร้อม heatmap และค่าความมั่นใจ

6.2 ข้อจำกัดของโครงการ

6.2.1 ชุดข้อมูลมีเพียง 2 ประเภท คือ “ปกติ” และ “วัณโรค” จึงไม่สามารถจำแนกโรคอื่นที่ปรากฏในภาพ X-ray ได้ เช่น ปอดบวม มะเร็งปอด หรือโรคระบบทางเดินหายใจอื่น ๆ

6.2.2 ข้อมูลที่ใช้มีจำนวนจำกัดเพียง 9,794 ภาพ และมาจากแหล่งข้อมูลเฉพาะ จึงอาจไม่ครอบคลุมความหลากหลายของภาพจากโรงพยาบาลหรืออุปกรณ์ที่แตกต่างกัน

6.2.3 โมเดลที่พัฒนาขึ้นและแอปพลิเคชันที่สร้างขึ้นในโครงการนี้เป็นเพียง **เครื่องมือช่วยคัดกรองเบื้องต้น** ไม่สามารถใช้ทดแทนการวินิจฉัยของแพทย์ได้

6.2.4 การใช้เทคนิค XAI เช่น Grad-CAM, LIME, และ SHAP ยังมีข้อจำกัดด้านความแม่นยำในการตีความ ซึ่งอาจทำให้ผลลัพธ์ที่แสดงออกมามี้อาจไม่สามารถสื่อสารได้ชัดเจนในบางกรณี

6.2.5 เว็บแอปพลิเคชันที่พัฒนายังอยู่ในระดับต้นแบบ (Prototype) และยังไม่ได้ผ่านการทดสอบใช้งานจริงในสภาพแวดล้อมของโรงพยาบาลหรือหน่วยงานทางการแพทย์

7. สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

8. ประโยชน์ที่คาดว่าจะได้รับ

8.1 ได้โมเดลปัญญาประดิษฐ์ (AI) ที่สามารถจำแนกภาพเอกซเรย์ทรวงอกเป็น “ปกติ” และ “วัณโรค” ได้อย่างแม่นยำ โดยมีความแม่นยำ (Accuracy) สูงกว่า **90%** บนชุดข้อมูลทดสอบ

8.2 ได้ระบบที่สามารถอธิบายเหตุผลเบื้องหลังการตัดสินใจของโมเดล (ด้วยเทคนิค XAI เช่น Grad-CAM, LIME หรือ SHAP) ซึ่งช่วยเพิ่มความน่าเชื่อถือ โปร่งใส และสามารถตรวจสอบได้

8.3 ได้เว็บแอปพลิเคชันที่สามารถใช้งานจริง ช่วยให้แพทย์หรือบุคลากรทางการแพทย์สามารถอัปโหลดภาพเอกซเรย์และรับผลการวิเคราะห์พร้อมคำอธิบายได้สะดวกและรวดเร็ว

8.4 ลดภาระงานในการวินิจฉัยเบื้องต้นของบุคลากรทางการแพทย์ โดยเฉพาะในพื้นที่ที่มีข้อจำกัดด้านทรัพยากรหรือขาดแคลนผู้เชี่ยวชาญ

8.5 สนับสนุนการนำเทคโนโลยี AI และ XAI ไปประยุกต์ใช้ในระบบสาธารณสุข เพื่อการวินิจฉัยโรคอย่างแม่นยำและยั่งยืนในอนาคต

9. แผนและระยะเวลาดำเนินการ

ตารางการดำเนินงานและระยะเวลา

การดำเนินงาน	ปี 2568					ปี 2569			
	7	8	9	10	11	12	1	2	3
1. ศึกษาและรวบรวมข้อมูล									
2. พัฒนาและฝึกอบรมโมเดล									
3. ประยุกต์ XAI และทดสอบประสิทธิภาพ									
4. พัฒนาเว็บแอปและทดสอบผู้ใช้									
5. สรุปผลและเขียนรายงาน									

หมายเหตุ ปรับตามความเหมาะสม ทั้งนี้ต้องระบุช่วงที่เสนอเค้าโครงงาน

10. งบประมาณ

10.1 หมวดค่าใช้จ่ายอื่นๆ

10.1.1 ค่าเช่าบริการระบบคลาวด์ (Cloud Services)

10.1.2 ค่าบริการกูเกิล โคลแลบ โพร (Google Colab Pro)

11. เอกสารอ้างอิง

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778).

Mindphp. (2023). *CNN คืออะไร?* From Mindphp: <https://www.mindphp.com/บทเรียนออนไลน์/python-tensorflow/10204-what-cnn.html>

Nwadiugwu, M. C. (2020). *Neural networks, artificial intelligence and the computational brain*. arXiv.

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 60.

Tangerine. (n.d.). *What is deep learning?* From Tangerine: <https://www.tangerine.co.th/blogs/data-analytics-artificial-intelligence/what-is-deep-learning>

Wang, Q., Zhang, Z., Zhang, H., Li, C., Liu, Y., & Wang, Y. (2024). *A survey of explainable artificial intelligence in medical imaging: From methods to applications* (arXiv:2503.08420). arXiv. <https://arxiv.org/abs/2503.08420>

ลงชื่อผู้ทำโครงการ **เกษม**

(นายเกษม คุ้มภัย)

วันที่ 31 / ก.ค. / 2568

ลงชื่อผู้ทำโครงการ **ภูวดล**

(นายภูวดล เมืองจันทร์)

วันที่ 31 / ก.ค. / 2568

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงการ

ตรวจแล้ว ให้เพิ่ม flow diagram ของแต่ละส่วน และผลลัพธ์พร้อมอภิปรายผล

(ลงชื่อ) **ms**

(พบพร ด้านวิทย์)

วันที่ 31 / ก.ค. / 2568